

Praktikum 10 Data Mining

Analisis Data Eksploratif:

Model Prediksi Time Series: Pengaruh Konversi Tutupan Lahan dan Emisi Terhadap Anomali Suhu di Kawasan Tropis

Adam Naufal — G6401231082

Muhammad Agung Rizkiansyah — G6401231096

Rafif Muhammad Farras — G6401231102

Daffa Kautsar Falih — G6401231150

Lembar Kerja Praktikum 10

1 Judul Proyek

Model Prediksi Time Series: Pengaruh Konversi Tutupan Lahan dan Emisi Terhadap Anomali Suhu di Kawasan Tropis Sebagai Early Warning System Berbasis Deep Learning.

2 Sumber Data

Data bersumber dari basis data resmi **Food and Agriculture Organization (FAO)** Perserikatan Bangsa-Bangsa, serta referensi klasifikasi wilayah tropis:

Domain	Link
Data Suhu (GT)	https://www.fao.org/faostat/en/#data/GT
Data Emisi (ET)	https://www.fao.org/faostat/en/#data/ET
Data Tutupan Lahan (LC)	https://www.fao.org/faostat/en/#data/LC
Referensi Negara Tropis	https://worldpopulationreview.com/country-rankings/tropical-countries

3 Penjelasan Data

Dataset yang digunakan merupakan hasil penggabungan (*merge*) dari tiga domain utama FAO, disimpan dalam file `Merged_Climate_LandCover_Data.csv`. Versi yang sudah difilter untuk negara-negara tropis tersedia di `Tropical_Climate_LandCover_Data.csv`. Rentang waktu dataset mencakup tahun **1992–2022** (31 tahun), dengan unit analisis per negara per tahun.

3.1 Data Iklim — *Temperature Change* (GT)

- **Area:** Nama negara/wilayah.
- **Year:** Tahun observasi (1992–2022).
- **Temperature_Change:** Anomali suhu permukaan (°C) relatif terhadap baseline 1951–1980.

3.2 Data Tutupan Lahan — *Land Cover* (LC)

- **Artificial surfaces:** Luas permukaan buatan/urban (1.000 ha).
- **Grassland:** Luas padang rumput.
- **Herbaceous crops:** Luas tanaman herba.
- **Tree-covered areas:** Luas area berhutan.
- **Shrub-covered areas:** Luas area semak.
- **Mangroves:** Luas hutan mangrove.
- **Inland water bodies:** Luas perairan darat.
- **Permanent snow and glaciers:** Luas salju/gletser permanen.
- **Terrestrial barren land:** Luas lahan tandus.
- **Woody crops:** Luas tanaman berkayu.

3.3 Data Emisi — *Emissions* (ET)

- **AFOLU:** *Agriculture, Forestry and Other Land Use emissions*.
- **Agrifood systems:** Total emisi sistem pangan.
- **Energy:** Emisi dari sektor energi.
- **LULUCF:** *Land Use, Land-Use Change and Forestry*.
- **Enteric Fermentation:** Emisi dari fermentasi enterik ternak.

- Forest fires: Emisi dari kebakaran hutan.
- Net Forest conversion: Emisi dari konversi hutan bersih.
- Dan 30+ sub-kategori emisi lainnya.

Alur Logika Dataset:

Perubahan Tutupan Lahan → Emisi → Akumulasi → Anomali Suhu

4 Langkah-Langkah Pembacaan Data

4.1 Import Library

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 import warnings
6 warnings.filterwarnings('ignore')
7
8 plt.style.use('seaborn-v0_8-darkgrid')
9 sns.set_palette('husl')
10 pd.set_option('display.max_columns', 20)
11 pd.set_option('display.float_format', '{:.2f}'.format)
12 print('Library berhasil diimport!')
```

4.2 Membaca Dataset

```
1 df = pd.read_csv('Merged_Climate_LandCover_Data.csv')
2 print(f'Dataset berhasil dimuat!')
3 print(f'Jumlah baris: {df.shape[0]:,}')
4 print(f'Jumlah kolom: {df.shape[1]}')
5 print(f'Rentang tahun: {df["Year"].min()} - {df["Year"].max()}')
6 print(f'Jumlah Area unik: {df["Area"].nunique()}')
7 df.head()
```

4.3 Informasi Struktur Data

```
1 df.info()
```

Perintah `df.info()` menampilkan tipe data setiap kolom, jumlah non-null values, dan perkiraan penggunaan memori. Ini penting untuk mengidentifikasi kolom yang perlu konversi tipe dan kolom dengan potensi missing values.

Table 1: Ringkasan Struktur Data Hasil `df.info()`

No.	Kolom	Non-Null Count	Tipe Data
0	Area	8128	object
1	Year	8128	int64
2	Temperature_Change	7810	float64
3	Artificial surfaces (including urban and associated areas)	8128	float64
4	Grassland	8128	float64
5	Herbaceous crops	8128	float64
6	Inland water bodies	8128	float64
7	Mangroves	8128	float64
8	Permanent snow and glaciers	8128	float64
9	Shrub-covered areas	8128	float64
10	Shrubs and/or herbaceous vegetation, aquatic or regularly flooded	8128	float64
11	Sparsely natural vegetated areas	8128	float64
12	Terrestrial barren land	8128	float64
13	Tree-covered areas	8128	float64
14	Woody crops	8128	float64
15	AFOLU	8128	float64
16	Agricultural Soils	8128	float64
17	Agrifood Systems Waste Disposal	8066	float64
18	Agrifood systems	8128	float64
19	All sectors with LULUCF	8128	float64
20	All sectors without LULUCF	8128	float64
21	Burning - Crop residues	6763	float64
22	Crop Residues	6819	float64
23	Drained organic soils	8128	float64
24	Drained organic soils (CO2)	8128	float64
25	Drained organic soils (N2O)	8128	float64
26	Emissions from crops	7288	float64
27	Emissions from livestock	7206	float64
28	Emissions on agricultural land	8128	float64
29	Energy	7353	float64
30	Enteric Fermentation	7185	float64
31	Farm gate	8128	float64
32	Fertilizers Manufacturing	3427	float64
33	Fires in humid tropical forests	8004	float64
34	Fires in organic soils	8004	float64
35	Food Household Consumption	7686	float64
36	Food Packaging	5011	float64
37	Food Processing	4339	float64
38	Food Retail	7536	float64
39	Food Transport	7871	float64
40	Forest fires	8066	float64
41	Forestland	7985	float64
42	IPCC Agriculture	8128	float64
43	IPPU	7384	float64
44	International bunkers	31	float64
45	LULUCF	8128	float64
46	Land-use change	8097	float64
47	Manure Management	7215	float64
48	Manure applied to Soils	7206	float64
49	Manure left on Pasture	7206	float64
50	Net Forest conversion	7985	float64
51	On-farm energy use	6209	float64
52	Other	7291	float64
53	Pesticides Manufacturing	7435	float64
54	Pre- and post-production	8128	float64
55	Rice Cultivation	4724	float64
56	Savanna fires	8128	float64
57	Synthetic Fertilizers	7216	float64
58	Waste	7384	float64

Dataset memiliki 8128 baris, 59 kolom, komposisi tipe data berupa 57 kolom `float64`, 1 kolom `int64`, dan 1 kolom `object`, dengan penggunaan memori sekitar 3.7 MB.

4.4 Statistik Deskriptif

```
1 df.describe().T
```

Statistik deskriptif ditranspose (.T) agar lebih mudah dibaca saat jumlah kolom banyak. Output mencakup count, mean, std, min, kuartil (25%, 50%, 75%), dan max untuk setiap variabel numerik.

Table 2: Statistik Deskriptif Variabel Numerik

Variabel	count	mean	std	min	25%	50%	75%	max
Year	8128.00	2007.03	8.94	1992.00	1999.00	2007.00	2015.00	2022.00
Temperature_Change	7810.00	0.92	0.57	-1.86	0.55	0.88	1.24	3.70
Artificial surfaces (including urban and associated areas)	8128.00	750.69	3422.84	0.00	3.78	32.20	193.33	64749.54
Grassland	8128.00	32865.95	133730.63	0.00	39.59	922.31	7618.13	1813817.46
Herbaceous crops	8128.00	34495.68	138813.76	0.00	31.35	1921.84	9424.20	1913692.10
Inland water bodies	8128.00	6910.20	33181.29	0.00	29.83	195.35	1312.42	436125.67
Mangroves	8128.00	366.00	1577.27	0.00	0.00	0.20	47.27	20607.85
Permanent snow and glaciers	8128.00	7999.17	88916.62	0.00	0.00	0.00	0.00	1405285.91
Shrub-covered areas	8128.00	29307.74	121521.78	0.00	14.88	444.08	6908.18	1611913.29
Shrubs and/or herbaceous vegetation, aquatic or regularly flooded	8128.00	3368.87	16062.71	0.00	0.27	18.72	320.63	204706.75
Sparsely natural vegetated areas	8128.00	15136.44	67874.49	0.00	0.16	11.28	1273.51	905626.91
Terrestrial barren land	8128.00	38367.60	163101.67	0.00	0.06	8.11	2827.51	1948238.01
Tree-covered areas	8128.00	76112.92	325723.05	0.00	84.64	2355.81	18648.59	4340886.13
Woody crops	8128.00	3787.80	16053.16	0.00	7.08	182.66	1120.85	242172.13
AFOLU	8128.00	77974.08	324911.01	-	46.53	3327.38	27486.23	4639479.45
			302939.18					
Agricultural Soils	8128.00	27410.18	100922.91	0.00	71.64	1579.64	8997.05	1857436.97
Agri-food Systems Waste Disposal	8066.00	15531.82	68283.96	0.00	80.66	846.56	4549.22	954430.32
Agri-food systems	8128.00	102356.82	422527.93	0.00	586.48	6269.16	35554.62	6111846.48
All sectors with LULUCF	8128.00	234249.08	1024404.53	-	997.98	14146.55	74224.76	16123523.72
			14892.26					
All sectors without LULUCF	8128.00	226457.58	1013975.98	0.00	906.19	12285.89	63860.83	16034430.92
Burning - Crop residues	6763.00	439.06	1511.05	0.00	3.14	25.99	153.49	25222.68
Crop Residues	6819.00	3298.91	12298.90	0.00	15.77	161.35	1086.63	196571.04
Drained organic soils	8128.00	13492.48	55731.08	0.00	0.00	6.51	2728.97	922825.66
Drained organic soils (CO2)	8128.00	12705.96	50467.37	0.00	0.00	4.61	2889.29	830402.62
Drained organic soils (N2O)	8128.00	1410.13	6117.87	0.00	0.00	0.58	194.68	92450.58
Emissions from crops	7288.00	17877.75	80995.32	0.00	37.87	498.07	4214.76	1035938.18
Emissions from livestock	7206.00	52646.11	201586.71	0.34	524.65	3669.17	19064.09	2849545.47
Emissions on agricultural land	8128.00	103731.08	426281.92	0.00	268.33	5532.67	33998.05	6198340.87
Energy	7353.00	212330.40	941979.98	1.22	1176.19	8034.28	64828.23	13928091.32
Enteric Fermentation	7185.00	51079.77	175510.33	0.03	466.17	3699.02	19200.76	2918397.22
Farm gate	8128.00	77083.55	317131.70	0.00	179.93	4751.61	26153.89	4713739.81
Fertilizers Manufacturing	3427.00	8102.42	24871.64	0.00	164.60	794.09	3911.15	267316.20
Fires in humid tropical forests	8004.00	2406.09	11204.43	0.00	0.00	0.00	31.84	140089.16
Fires in organic soils	8004.00	2586.58	27517.41	0.00	0.00	0.00	0.00	628166.33
Food Household Consumption	7686.00	3910.51	18357.46	0.00	5.20	79.27	1003.75	323905.27
Food Packaging	5011.00	1798.75	7068.23	0.00	2.17	44.60	519.33	79878.97
Food Processing	4339.00	4084.61	13672.77	0.00	4.13	131.13	1276.02	148649.38
Food Retail	7536.00	2830.13	13162.14	0.00	16.76	139.88	911.31	278601.88
Food Transport	7871.00	1963.50	8278.73	0.00	13.53	95.18	681.03	138705.44
Forest fires	8066.00	2999.37	12650.24	0.00	0.00	1.30	156.02	124174.04
Forestland	7985.00	-	296729.60	-	-8415.19	-209.00	0.00	147927.35
		64951.53	4099231.24					
IPCC Agriculture	8128.00	66684.87	250588.33	0.00	162.95	4049.73	22237.36	4073285.58
IPPU	7384.00	18342.49	88434.92	0.00	44.63	634.48	4901.42	1479800.68
International bunkers	31.00	356057.14	70292.35	242320.11	299711.75	361176.22	403286.94	474939.83
LULUCF	8128.00	5927.58	112436.00	-	-613.71	0.00	2012.02	911872.27
			2821790.03					
Land-use change	8097.00	10674.55	128103.84	0.00	0.00	43.54	2636.34	2269901.21

Lanjut ke halaman berikutnya

Variabel	count	mean	std	min	25%	50%	75%	max
Manure Management	7215.00	4893.37	17927.82	0.05	39.86	294.93	1701.86	266140.56
Manure applied to Soils	7206.00	2755.95	9711.10	0.05	23.31	181.50	950.22	163794.72
Manure left on Pasture	7206.00	13376.45	44795.59	0.00	131.33	950.90	5268.74	792915.22
Net Forest conversion	7985.00	63672.52	286766.77	-1544.24	0.00	264.03	7027.50	3595409.66
On-farm energy use	6209.00	6285.17	25719.89	0.00	12.87	227.82	2275.67	363720.66
Other	7291.00	2515.72	9726.86	0.00	38.56	185.50	971.22	123296.44
Pesticides Manufacturing	7435.00	1238.50	6615.59	0.00	0.61	5.74	100.28	116740.33
Pre- and post-production	8128.00	24501.66	110033.11	0.00	116.26	1216.44	7081.52	1812492.44
Rice Cultivation	4724.00	18259.52	65994.81	0.00	37.79	424.86	4260.65	693929.70
Savanna fires	8128.00	3566.05	14879.63	0.00	0.00	4.24	360.73	147509.01
Synthetic Fertilizers	7216.00	9248.11	37162.35	-0.69	12.52	238.52	1978.17	625000.46
Waste	7384.00	19407.64	80077.24	0.06	234.81	1230.27	7360.14	1291126.56

4.5 Analisis Missing Values

```

1 missing = df.isnull().sum()
2 missing_pct = (missing / len(df) * 100).round(2)
3 missing_df = pd.DataFrame({
4     'Jumlah Missing': missing,
5     'Persentase (%)': missing_pct
6 })
7 missing_df = missing_df[missing_df['Jumlah Missing'] > 0]\
8     .sort_values('Persentase (%)', ascending=False)
9 print(f'Kolom dengan missing values: {len(missing_df)} dari {df.shape[1]}
10     kolom')
11 missing_df

```

Table 3: Ringkasan Missing Values pada Variabel yang Tidak Lengkap

Variabel	Jumlah Missing	Persentase (%)
International bunkers	8097	99.62
Fertilizers Manufacturing	4701	57.84
Food Processing	3789	46.62
Rice Cultivation	3404	41.88
Food Packaging	3117	38.35
On-farm energy use	1919	23.61
Burning - Crop residues	1365	16.79
Crop Residues	1309	16.10
Enteric Fermentation	943	11.60
Manure applied to Soils	922	11.34
Manure left on Pasture	922	11.34
Emissions from livestock	922	11.34
Manure Management	913	11.23
Synthetic Fertilizers	912	11.22
Emissions from crops	840	10.33
Other	837	10.30
Energy	775	9.53
IPPU	744	9.15
Waste	744	9.15
Pesticides Manufacturing	693	8.53
Food Retail	592	7.28
Food Household Consumption	442	5.44
Temperature_Change	318	3.91

Lanjut ke halaman berikutnya

Variabel	Jumlah Missing	Persentase (%)
Food Transport	257	3.16
Forestland	143	1.76
Net Forest conversion	143	1.76
Fires in organic soils	124	1.53
Fires in humid tropical forests	124	1.53
Agrifood Systems Waste Disposal	62	0.76
Forest fires	62	0.76
Land-use change	31	0.38

```

1 fig, ax = plt.subplots(figsize=(12, 6))
2 top_missing = missing_df.head(15)
3 colors = plt.cm.Reds(np.linspace(0.3, 0.9, len(top_missing)))
4 bars = ax.barh(top_missing.index, top_missing['Persentase (%)'],
5               color=colors)
6 ax.set_xlabel('Persentase Missing (%)', fontsize=12)
7 ax.set_title('Top 15 Kolom dengan Missing Values Terbanyak',
8             fontsize=14, fontweight='bold')
9 for bar, val in zip(bars, top_missing['Persentase (%)']):
10     ax.text(bar.get_width() + 0.5,
11           bar.get_y() + bar.get_height()/2,
12           f'{val}%', va='center', fontsize=9)
13 plt.tight_layout()
14 plt.show()

```




Figure 1: Missing Values Terbanyak

Missing Values:

- International bunkers memiliki missing value tertinggi (~99.6%) karena tidak semua negara melaporkan emisi dari penerbangan/pelayaran internasional.
- Fertilizers Manufacturing, Food Processing, dan Food Packaging juga tinggi karena data industri ini tidak tersedia untuk semua negara.
- Kolom utama (Temperature_Change, Area, Year) memiliki missing value sangat rendah sehingga tetap layak dianalisis.

4.6 Filtering Data Negara Tropis

Filtering dilakukan menggunakan referensi klasifikasi “Fully Tropical” dari dataset tropical-countries-2026.csv yang bersumber dari World Population Review. Pendekatan ini lebih akurat dibanding daftar manual karena menggunakan klasifikasi geografis yang konsisten.

```

1 import os
2
3 tropical_csv = 'Merged_Climate_LandCover_Data_FullyTropical.csv'
4 ref_csv = 'tropical-countries-2026.csv'
5
6 if os.path.exists(tropical_csv):
7     # Langsung gunakan file yang sudah difilter
8     df_tropical = pd.read_csv(tropical_csv)
9     print(f'Loaded pre-filtered tropical data: {tropical_csv}')
10 else:
11     # Filter dari data utama menggunakan referensi "Fully Tropical"
12     ref = pd.read_csv(ref_csv)
13     fully = ref[ref['tropicalCountries_fullyTropical'] == 'Fully Tropical']
14
15     # Mapping nama referensi -> nama FAOSTAT
16     name_map = {
17         'DR Congo': 'Democratic Republic of the Congo',
18         'Vietnam': 'Viet Nam',
19         'Tanzania': 'United Republic of Tanzania',
20         'Republic of the Congo': 'Congo',
21         'Laos': "Lao People's Democratic Republic",
22         'Cape Verde': 'Cabo Verde',
23         'Micronesia': 'Micronesia (Federated States of)',
24         'Venezuela': 'Venezuela (Bolivarian Republic of)',
25     }
26
27     # Build FAOSTAT name set
28     faostat_names = set()
29
30     # Temukan nama "Cote d'Ivoire" dengan encoding asli dari dataset
31     cote = [a for a in df['Area'].unique() if 'ivoire' in a.lower()]
32
33     for _, row in fully.iterrows():
34         ref_name = row['country']
35         if ref_name == 'Ivory Coast':

```



```

36         faostat_names.update(cote)
37     elif ref_name in name_map:
38         faostat_names.add(name_map[ref_name])
39     else:
40         faostat_names.add(ref_name)
41
42     # Tambahkan entri historis
43     for e in ['Ethiopia PDR', 'Sudan (former)']:
44         if e in df['Area'].unique():
45             faostat_names.add(e)
46
47     df_tropical = df[df['Area'].isin(faostat_names)].copy()
48
49     # Simpan hasil agar os.path.exists bekerja untuk run selanjutnya
50     df_tropical.to_csv(tropical_csv, index=False)
51     print(f'Filtered and saved fully tropical data to: {tropical_csv}')
52
53     print(f'Jumlah negara tropis (Fully Tropical): {df_tropical["Area"].nunique()}')
54     print(f'Total data points: {len(df_tropical):,}')
55     print(f'Rentang tahun: {df_tropical["Year"].min()} - {df_tropical["Year"].max()}')
56     print(f'\nDaftar negara ({df_tropical["Area"].nunique()}):')
57     for i, c in enumerate(sorted(df_tropical['Area'].unique()), 1):
58         print(f'    {i:2d}. {c}')

```

Keterangan	Hasil
File hasil filter	Merged_Climate_LandCover_Data_FullyTropical.csv
Jumlah negara tropis (<i>Fully Tropical</i>)	98
Total data points	2,955
Rentang tahun	1992–2022

Table 4: Daftar 98 Negara Tropis Kategori *Fully Tropical*

No.	Negara
1	Angola
2	Antigua and Barbuda
3	Aruba
4	Barbados
5	Belize
6	Benin
7	British Virgin Islands
8	Burkina Faso
9	Burundi
10	Cabo Verde
11	Cambodia
12	Cameroon
13	Central African Republic
14	Chad
15	Colombia
16	Comoros

Lanjut ke halaman berikutnya

No.	Negara
17	Congo
18	Costa Rica
19	Cuba
20	Côte d'Ivoire
21	Democratic Republic of the Congo
22	Djibouti
23	Dominica
24	Dominican Republic
25	Ecuador
26	El Salvador
27	Equatorial Guinea
28	Eritrea
29	Ethiopia
30	Ethiopia PDR
31	Fiji
32	French Guiana
33	Gabon
34	Gambia
35	Ghana
36	Grenada
37	Guadeloupe
38	Guatemala
39	Guinea
40	Guinea-Bissau
41	Guyana
42	Haiti
43	Honduras
44	Indonesia
45	Jamaica
46	Kenya
47	Kiribati
48	Lao People's Democratic Republic
49	Liberia
50	Malawi
51	Malaysia
52	Maldives
53	Mali
54	Marshall Islands
55	Martinique
56	Mauritania
57	Mauritius
58	Micronesia (Federated States of)
59	Nauru
60	Nicaragua
61	Niger
62	Nigeria
63	Palau
64	Panama
65	Papua New Guinea
66	Peru
67	Philippines
68	Rwanda
69	Saint Kitts and Nevis
70	Saint Lucia
71	Saint Vincent and the Grenadines
72	Samoa
73	Sao Tome and Principe
74	Senegal
75	Seychelles
76	Sierra Leone
77	Singapore
78	Solomon Islands
79	Somalia
80	South Sudan
81	Sri Lanka
82	Sudan

Lanjut ke halaman berikutnya

No.	Negara
83	Sudan (former)
84	Suriname
85	Thailand
86	Timor-Leste
87	Togo
88	Tonga
89	Trinidad and Tobago
90	Tuvalu
91	Uganda
92	United Republic of Tanzania
93	United States Virgin Islands
94	Vanuatu
95	Venezuela (Bolivarian Republic of)
96	Viet Nam
97	Yemen
98	Zambia

5 Bentuk Eksplorasi Data dan Hasilnya

5.1 Tren Anomali Suhu di Negara Tropis

```

1 temp_trend = df_tropical.groupby('Year')['Temperature_Change']\
2               .agg(['mean', 'std', 'min', 'max']).reset_index()
3
4 fig, ax = plt.subplots(figsize=(14, 6))
5 ax.fill_between(temp_trend['Year'],
6                 temp_trend['min'], temp_trend['max'],
7                 alpha=0.15, color='red', label='Range (Min-Max)')
8 ax.fill_between(temp_trend['Year'],
9                 temp_trend['mean']-temp_trend['std'],
10                 temp_trend['mean']+temp_trend['std'],
11                 alpha=0.3, color='orange', label='+-1 Std Dev')
12 ax.plot(temp_trend['Year'], temp_trend['mean'],
13         'r-o', linewidth=2, markersize=5, label='Rata-rata')
14 ax.axhline(y=0, color='gray', linestyle='--', alpha=0.5)
15 ax.set_xlabel('Tahun', fontsize=12)
16 ax.set_ylabel('Anomali Suhu (derajat C)', fontsize=12)
17 ax.set_title('Tren Anomali Suhu Rata-rata Negara Tropis (1992-2022)',
18             fontsize=14, fontweight='bold')
19 ax.legend(fontsize=10)
20 plt.tight_layout()
21 plt.show()

```




Figure 2: Tren Anomali Suhu Rata-Rata Negara Tropis (1992 - 2022)

Grafik tren suhu menampilkan garis rata-rata (merah), pita ± 1 standar deviasi (oranye), dan rentang min-maks (merah muda) untuk seluruh negara tropis dari 1992 hingga 2022. Terlihat tren kenaikan yang konsisten sepanjang periode tersebut.

5.2 Perbandingan Anomali Suhu: Top 10 Negara Tropis

```

1 latest = df_tropical[df_tropical['Year'] == df_tropical['Year'].max()]
2 top10_hot = latest.nlargest(10, 'Temperature_Change')[
3     ['Area', 'Temperature_Change']]
4
5 fig, ax = plt.subplots(figsize=(12, 6))
6 colors = plt.cm.YlOrRd(np.linspace(0.3, 0.95, len(top10_hot)))
7 bars = ax.barh(top10_hot['Area'], top10_hot['Temperature_Change'],
8               color=colors)
9 ax.set_xlabel('Anomali Suhu (derajat C)', fontsize=12)
10 ax.set_title(
11     f'Top 10 Negara Tropis dengan Anomali Suhu Tertinggi '
12     f'({df_tropical["Year"].max()})',
13     fontsize=14, fontweight='bold')
14 for bar, val in zip(bars, top10_hot['Temperature_Change']):
15     ax.text(bar.get_width() + 0.02,
16             bar.get_y() + bar.get_height()/2,
17             f'{val:.2f} C', va='center', fontsize=10)
18 plt.tight_layout()
19 plt.show()

```




Figure 3: Bar Chart 10 Negara Tropis dengan Anomali Suhu Tertinggi (2022)

Bar chart horizontal memvisualisasikan 10 negara tropis dengan anomali suhu tertinggi pada tahun terakhir dataset (2022), dengan gradasi warna dari kuning ke merah menunjukkan intensitas anomali.

5.3 Perubahan Tutupan Lahan di Negara Tropis

```

1 lc_cols = ['Tree-covered areas', 'Herbaceous crops', 'Grassland',
2           'Shrub-covered areas',
3           'Artificial surfaces (including urban and associated areas)']
4
5 lc_trend = df_tropical.groupby('Year')[lc_cols].mean().reset_index()
6
7 fig, ax = plt.subplots(figsize=(14, 7))
8 for col in lc_cols:
9     short = col.replace(
10         ' (including urban and associated areas)', '')
11     ax.plot(lc_trend['Year'], lc_trend[col],
12            '-o', linewidth=2, markersize=4, label=short)
13 ax.set_xlabel('Tahun', fontsize=12)
14 ax.set_ylabel('Rata-rata Luas (1000 ha)', fontsize=12)
15 ax.set_title('Tren Rata-rata Tutupan Lahan Negara Tropis (1992-2022)',
16            fontsize=14, fontweight='bold')
17 ax.legend(fontsize=9, loc='center left', bbox_to_anchor=(1, 0.5))
18 plt.tight_layout()
19 plt.show()

```




Figure 4: Line Chart Tren Rata-Rata Tutupan Lahan Negara Tropis (1992-2022)

Line chart multi-warna menampilkan tren rata-rata luas setiap kelas tutupan lahan dari 1992 hingga 2022. Terlihat pola penurunan Tree-covered areas dan peningkatan Herbaceous crops serta Artificial surfaces.

5.4 Tren Emisi Utama

```

1 emission_cols = ['AFOLU', 'Agrifood systems', 'Energy',
2                  'LULUCF', 'Net Forest conversion']
3 avail = [c for c in emission_cols if c in df_tropical.columns]
4
5 em_trend = df_tropical.groupby('Year')[avail].mean().reset_index()
6
7 fig, axes = plt.subplots(2, 3, figsize=(18, 10))
8 axes = axes.flatten()
9 for i, col in enumerate(avail):
10     ax = axes[i]
11     ax.plot(em_trend['Year'], em_trend[col],
12            '-o', linewidth=2, markersize=4, color=f'C{i}')
13     ax.fill_between(em_trend['Year'], 0, em_trend[col],
14                    alpha=0.2, color=f'C{i}')
15     ax.set_title(col, fontsize=12, fontweight='bold')
16     ax.set_xlabel('Tahun')
17     ax.set_ylabel('Emisi (kt CO2eq)')
18     ax.tick_params(axis='x', rotation=45)
19 for j in range(len(avail), len(axes)):
20     axes[j].set_visible(False)
21 plt.suptitle('Tren Emisi Rata-rata Negara Tropis (1992-2022)',
22             fontsize=15, fontweight='bold', y=1.02)

```

```

23 plt.tight_layout()
24 plt.show()

```




Figure 5: Grid Subplot Tren Emisi Rata-Rata Negara Tropis (1992-2022)

Grid subplot 2×3 menampilkan tren setiap kategori emisi utama secara terpisah dengan area di bawah kurva diarsir, memudahkan perbandingan magnitudo antar kategori.

5.5 Heatmap Korelasi: Suhu vs Tutupan Lahan vs Emisi

```

1 corr_cols = ['Temperature_Change'] + lc_cols + [
2     'AFOLU', 'Agrifood systems', 'Energy',
3     'Enteric Fermentation', 'Forest fires', 'Net Forest conversion']
4 avail_corr = [c for c in corr_cols if c in df_tropical.columns]
5 corr_data = df_tropical[avail_corr].dropna()
6 corr_matrix = corr_data.corr()
7
8 fig, ax = plt.subplots(figsize=(14, 10))
9 mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
10 short_labels = [c.replace(
11     '(including urban and associated areas)', '')
12     for c in corr_matrix.columns]
13 sns.heatmap(corr_matrix, mask=mask, annot=True, fmt='.2f',
14     cmap='RdYlBu_r', center=0, square=True,
15     linewidths=0.5, ax=ax,
16     xticklabels=short_labels, yticklabels=short_labels,
17     cbar_kws={'label': 'Korelasi Pearson'})

```

```

18 ax.set_title(
19     'Heatmap Korelasi: Anomali Suhu vs Tutupan Lahan vs Emisi',
20     fontsize=14, fontweight='bold')
21 plt.xticks(rotation=45, ha='right')
22 plt.tight_layout()
23 plt.show()

```

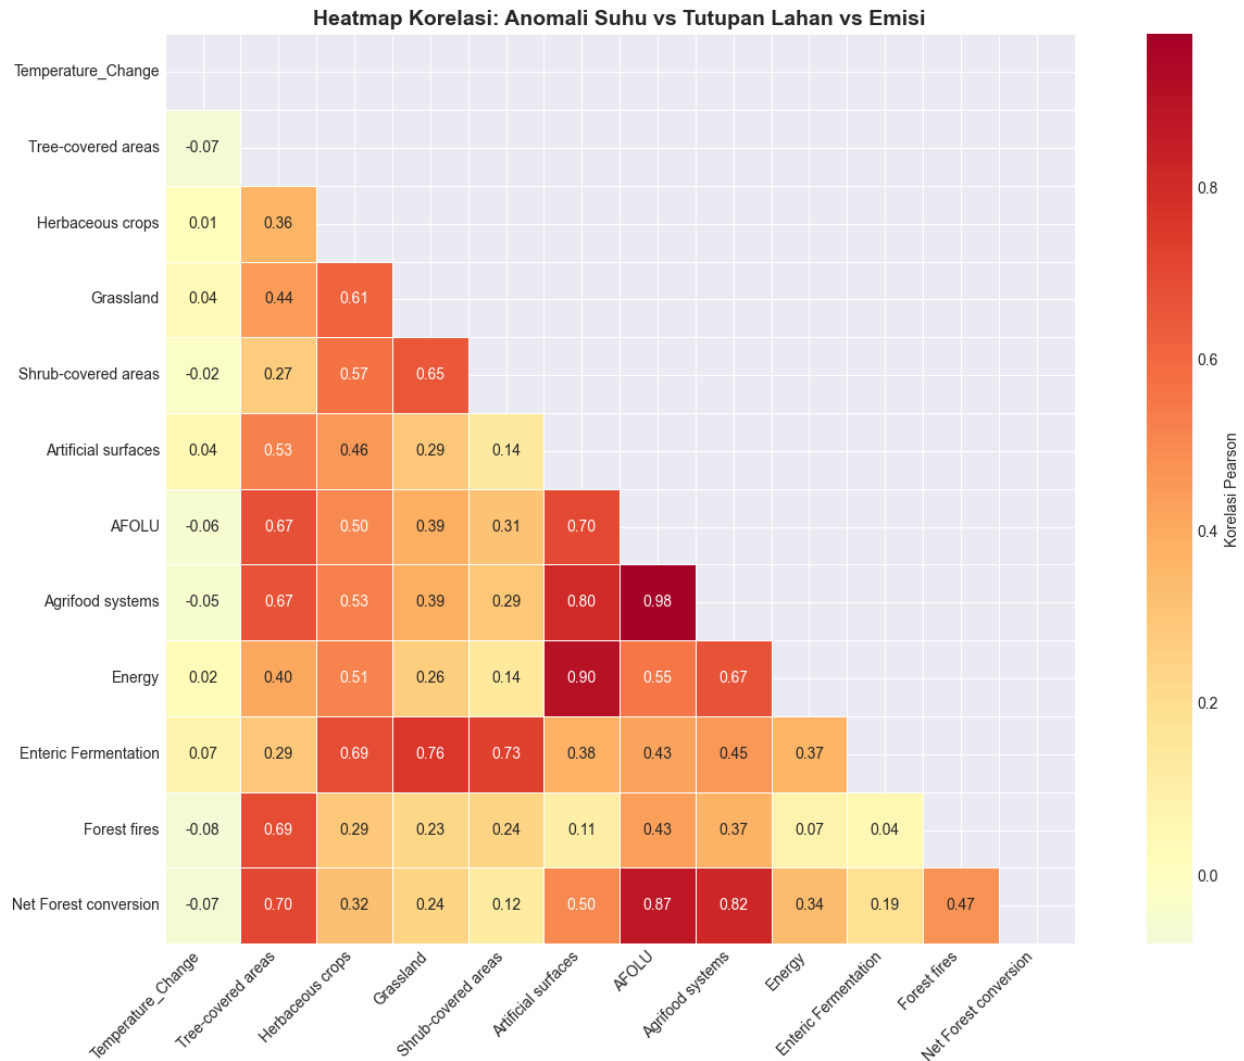


Figure 6: Heatmap Korelasi Pearson

Heatmap segitiga bawah menampilkan korelasi Pearson antar semua variabel. Warna merah menunjukkan korelasi positif kuat, biru menunjukkan korelasi negatif.

- Korelasi positif antara **Temperature_Change** dan **Artificial surfaces** menunjukkan urbanisasi berkontribusi pada pemanasan.
- Korelasi negatif antara **Temperature_Change** dan **Tree-covered areas** mengkonfirmasi bahwa deforestasi meningkatkan anomali suhu.

- AFOLU dan Agrifood systems menunjukkan korelasi kuat dengan emisi sub-sektor, sehingga memvalidasi integrasi data.

5.6 Analisis Time Series: Studi Kasus Indonesia

```

1 df_idn = df_tropical[df_tropical['Area'] == 'Indonesia']\
2     .sort_values('Year')
3
4 fig, axes = plt.subplots(3, 1, figsize=(14, 12), sharex=True)
5
6 # Panel 1: Temperature
7 axes[0].plot(df_idn['Year'], df_idn['Temperature_Change'],
8             'r-o', linewidth=2)
9 axes[0].axhline(y=0, color='gray', linestyle='--', alpha=0.5)
10 axes[0].set_ylabel('Anomali Suhu (derajat C)', fontsize=11)
11 axes[0].set_title(
12     'Indonesia: Anomali Suhu, Tutupan Lahan & Emisi (1992-2022)',
13     fontsize=14, fontweight='bold')
14 axes[0].legend(['Temperature Change'], loc='upper left')
15
16 # Panel 2: Land Cover
17 for col in ['Tree-covered areas', 'Herbaceous crops']:
18     if col in df_idn.columns:
19         axes[1].plot(df_idn['Year'], df_idn[col],
20                     '-o', linewidth=2, markersize=4, label=col)
21 axes[1].set_ylabel('Luas (1000 ha)', fontsize=11)
22 axes[1].legend(loc='center right')
23
24 # Panel 3: Emissions
25 for col in ['AFOLU', 'Net Forest conversion', 'Forest fires']:
26     if col in df_idn.columns:
27         axes[2].plot(df_idn['Year'], df_idn[col],
28                     '-o', linewidth=2, markersize=4, label=col)
29 axes[2].set_xlabel('Tahun', fontsize=12)
30 axes[2].set_ylabel('Emisi (kt CO2eq)', fontsize=11)
31 axes[2].legend(loc='upper right')
32
33 plt.tight_layout()
34 plt.show()

```




Figure 7: Anomali Suhu, Tutupan Lahan & Emisi di Indonesia (1992–2022)

Panel bertumpuk tiga-baris dengan sumbu-x bersama memungkinkan pembacaan langsung hubungan temporal antara anomali suhu, perubahan tutupan lahan, dan emisi di Indonesia.

- Anomali suhu menunjukkan tren naik yang konsisten
- Penurunan **Tree-covered areas** (deforestasi) terlihat jelas
- Spike emisi dari **Forest fires** dan **Net Forest conversion** berkorelasi dengan tahun-tahun kenaikan suhu ekstrem (1997-1998 El Niño, 2015-2016)

5.7 Scatter Plot: Deforestasi vs Anomali Suhu

```
1 fig, axes = plt.subplots(1, 2, figsize=(16, 6))
2 selected = ['Indonesia', 'Brazil', 'India', 'Nigeria', 'Colombia']
```

```

3
4 ax1 = axes[0]
5 for country in selected:
6     cdata = df_tropical[df_tropical['Area'] == country]
7     ax1.scatter(cdata['Tree-covered areas'],
8                 cdata['Temperature_Change'],
9                 label=country, alpha=0.7, s=40)
10 ax1.set_xlabel('Tree-covered areas (1000 ha)', fontsize=11)
11 ax1.set_ylabel('Anomali Suhu (derajat C)', fontsize=11)
12 ax1.set_title('Hubungan Luas Hutan vs Anomali Suhu',
13               fontsize=13, fontweight='bold')
14 ax1.legend(fontsize=9)
15
16 ax2 = axes[1]
17 for country in selected:
18     cdata = df_tropical[df_tropical['Area'] == country]
19     ax2.scatter(cdata['AFOLU'], cdata['Temperature_Change'],
20                 label=country, alpha=0.7, s=40)
21 ax2.set_xlabel('AFOLU Emissions (kt CO2eq)', fontsize=11)
22 ax2.set_ylabel('Anomali Suhu (derajat C)', fontsize=11)
23 ax2.set_title('Hubungan Emisi AFOLU vs Anomali Suhu',
24               fontsize=13, fontweight='bold')
25 ax2.legend(fontsize=9)
26
27 plt.tight_layout()
28 plt.show()

```




Figure 8: Scatter plot Hubungan Luas Hutan vs Anomali Suhu dan Hubungan Emisi AFOLU vs Anomali Suhu

Dua scatter plot berdampingan menampilkan hubungan antara (1) luas area hutan dengan anomali suhu, dan (2) emisi AFOLU dengan anomali suhu, untuk 5 negara tropis besar dengan warna berbeda per negara.

5.8 Distribusi Anomali Suhu per Dekade

```
1 df_tropical['Dekade'] = pd.cut(  
2     df_tropical['Year'],  
3     bins=[1991, 2000, 2010, 2022],  
4     labels=['1992-2000', '2001-2010', '2011-2022'])  
5  
6 fig, ax = plt.subplots(figsize=(12, 6))  
7 colors_d = ['#3498db', '#e67e22', '#e74c3c']  
8 for i, dekade in enumerate(['1992-2000', '2001-2010', '2011-2022']):  
9     data = df_tropical[df_tropical['Dekade'] == dekade]\  
10         ['Temperature_Change'].dropna()  
11     ax.hist(data, bins=30, alpha=0.5, label=dekade,  
12            color=colors_d[i], edgecolor='white')  
13 ax.axvline(x=0, color='black', linestyle='--', alpha=0.5)  
14 ax.set_xlabel('Anomali Suhu (derajat C)', fontsize=12)  
15 ax.set_ylabel('Frekuensi', fontsize=12)  
16 ax.set_title('Distribusi Anomali Suhu per Dekade (Negara Tropis)',  
17            fontsize=14, fontweight='bold')  
18 ax.legend(fontsize=11)  
19 plt.tight_layout()  
20 plt.show()  
21  
22 print('Statistik per Dekade:')  
23 print(df_tropical.groupby('Dekade')['Temperature_Change']  
24       .describe().round(3))
```




Figure 9: Distribusi Anomali Suhu per Dekade di Negara Tropis

Dekade	count	mean	std	min	25%	50%	75%	max
1992–2000	800.00	0.52	0.37	-0.83	0.28	0.49	0.72	1.75
2001–2010	899.00	0.79	0.31	0.07	0.58	0.78	0.98	1.94
2011–2022	1084.00	1.02	0.34	-0.03	0.78	1.01	1.23	2.14

- Distribusi anomali suhu bergeser ke kanan (lebih panas) dari dekade ke dekade
- Dekade 2011-2022 menunjukkan distribusi yang lebih condong ke anomali positif
- Ini mengkonfirmasi akselerasi pemanasan global di kawasan tropis

5.9 Box Plot Anomali Suhu per Negara (Top 15)

```

1 top15 = df_tropical.groupby('Area')['Temperature_Change']\
2     .mean().nlargest(15).index
3 df_top15 = df_tropical[df_tropical['Area'].isin(top15)]
4
5 fig, ax = plt.subplots(figsize=(14, 7))
6 order = df_top15.groupby('Area')['Temperature_Change']\
7     .mean().sort_values(ascending=False).index
8 sns.boxplot(data=df_top15, x='Area', y='Temperature_Change',
9             order=order, palette='YlOrRd', ax=ax)
10 ax.axhline(y=0, color='gray', linestyle='--', alpha=0.5)
11 ax.set_xlabel('')
12 ax.set_ylabel('Anomali Suhu (derajat C)', fontsize=12)
13 ax.set_title('Distribusi Anomali Suhu: Top 15 Negara Tropis Terpanas',
14             fontsize=14, fontweight='bold')
15 plt.xticks(rotation=45, ha='right')
16 plt.tight_layout()
17 plt.show()

```




Figure 10: Box Plot Anomali Suhu untuk 15 Negara Terpanas

5.10 Pairplot: Variabel Kunci

```

1 key_vars = ['Temperature_Change', 'Tree-covered areas',
2             'Herbaceous crops', 'AFOLU']
3 avail_kv = [c for c in key_vars if c in df_tropical.columns]
4 sample    = df_tropical[avail_kv + ['Area']].dropna()
5 five      = ['Indonesia', 'Brazil', 'India', 'Nigeria', 'Thailand']
6 sample5   = sample[sample['Area'].isin(five)]
7
8 g = sns.pairplot(sample5, hue='Area', vars=avail_kv,
9                   palette='husl',
10                  plot_kws={'alpha': 0.6, 's': 30},
11                  diag_kind='kde', height=2.5)
12 g.figure.suptitle(
13     'Pairplot Variabel Kunci (5 Negara Tropis Utama)',
14     fontsize=14, fontweight='bold', y=1.02)
15 plt.tight_layout()
16 plt.show()

```



Figure 11: Pairplot Variable Kunci untuk 5 Negara Tropis Utama

6 Interpretasi Data

6.1 Temuan Utama

- **Tren Pemanasan Konsisten:** Anomali suhu di kawasan tropis meningkat secara konsisten dari 1992 hingga 2022, dengan percepatan yang lebih terasa setelah tahun 2010. Distribusi anomali suhu per dekade bergeser ke kanan (lebih panas), mengkonfirmasi akselerasi pemanasan global di wilayah tropis.
- **Deforestasi Masif:** Terjadi penurunan signifikan pada **Tree-covered areas** yang diimbangi peningkatan **Herbaceous crops** dan **Artificial surfaces**. Ini

mengindikasikan konversi lahan hutan untuk pertanian dan urbanisasi secara masif di kawasan tropis selama 30 tahun terakhir.

- **Korelasi Emisi–Suhu:** Heatmap korelasi menunjukkan korelasi positif antara `Temperature_Change` dan `Artificial_surfaces` (urbanisasi berkontribusi pada pemanasan), serta korelasi negatif antara `Temperature_Change` dan `Tree-covered_areas` (deforestasi meningkatkan anomali suhu). Emisi AFOLU juga menunjukkan korelasi positif dengan anomali suhu.
- **Hotspot Indonesia:** Studi kasus Indonesia menunjukkan pola yang khas: penurunan `Tree-covered_areas` yang jelas, serta *spike* emisi dari `Forest fires` dan `Net Forest conversion` yang berkorelasi dengan tahun-tahun kenaikan suhu ekstrem (1997–1998 El Niño dan 2015–2016).
- **Distribusi Bergeser:** Distribusi anomali suhu per dekade bergeser ke arah positif, menunjukkan pemanasan sistematis yang tidak terbatas pada tahun-tahun anomali saja, melainkan merupakan perubahan struktural jangka panjang.

6.2 Implikasi untuk Pemodelan LSTM

- Data *time series* yang konsisten (31 tahun) sangat cocok untuk arsitektur LSTM/GRU.
- Efek *lagged* antara deforestasi dan kenaikan suhu (2–5 tahun) dapat ditangkap oleh mekanisme memori LSTM.
- *Missing values* perlu ditangani dengan interpolasi sebelum pemodelan untuk menjaga kontinuitas deret waktu.
- *Feature selection* berdasarkan matriks korelasi dapat meningkatkan performa model dengan mengurangi dimensionalitas.

6.3 Potensi Early Warning System

Dengan tren yang telah teridentifikasi melalui eksplorasi data ini, model prediktif berbasis *deep learning* dapat:

- Memprediksi anomali suhu 5 tahun ke depan berdasarkan tren konversi lahan yang sedang berjalan.
- Memberikan peringatan dini (*early warning*) apabila suatu negara melampaui ambang batas (*threshold*) deforestasi tertentu.
- Membantu pengambil kebijakan dalam perencanaan mitigasi perubahan iklim berbasis data empiris jangka panjang.

Dibuat untuk Lembar Kerja Praktikum 10 — Data Mining.

Dataset: Merged_Climate_LandCover_Data.csv (FAO) & tropical-countries-2026.csv (World Population Review).