

# Analisis Anomali Suhu ASEAN Berbasis Data Mining pada Data Perubahan Iklim, Emisi, dan Tutupan Lahan FAOSTAT

[Nama Anggota 1] ([NIM]), [Nama Anggota 2] ([NIM]), [Nama Anggota 3] ([NIM]) \*

Kelompok: [Nomor Kelompok], Kelas Paralel: [Nomor Paralel]

## Abstrak

Perubahan iklim dan perubahan tutupan lahan saling berkaitan melalui dinamika emisi, konversi hutan, urbanisasi, dan aktivitas agrifood. Tugas akhir ini mengimplementasikan pipeline data mining komprehensif pada data FAOSTAT untuk menganalisis anomali suhu negara-negara ASEAN dengan memanfaatkan panel global 269 negara tahun 1992-2022. Metode yang digunakan mencakup praproses data, clustering dan deteksi anomali, klasifikasi kategori suhu, deep learning LSTM/GRU dengan 288 konfigurasi hyperparameter, association rule mining, serta time series mining. Hasil menunjukkan seluruh 9 negara ASEAN yang memiliki target suhu bersifat non-stasioner berdasarkan uji ADF. Model deep learning terbaik berdasarkan validasi adalah LSTM dengan window 3, hidden 24, 2 layer, dropout 0.05, dan MAE validasi ASEAN 0.193. Pada data uji ASEAN, model terbaik keseluruhan tetap HistGradientBoosting dengan MAE 0.127, sedangkan GRU/LSTM menunjukkan keterbatasan akibat jumlah deret tahunan ASEAN yang kecil.

Kata Kunci: anomali suhu; ASEAN; data mining; deep learning; tutupan lahan

## PENDAHULUAN

### Latar Belakang

Perubahan iklim dipengaruhi oleh emisi gas rumah kaca, perubahan tutupan lahan, kebakaran hutan, urbanisasi, dan aktivitas pertanian. ASEAN penting dianalisis karena memiliki hutan tropis luas, aktivitas agrifood besar, serta kejadian kebakaran dan deforestasi. Dalam data mining, persoalan ini cocok dikaji sebagai data panel negara-tahun karena tiap negara memiliki profil emisi dan tutupan lahan berbeda, sementara suhu menunjukkan pola temporal yang terus berubah.

Permasalahan utama adalah tren waktu. Jika model memprediksi level anomali suhu langsung, korelasi tinggi dapat muncul hanya karena banyak variabel meningkat bersama waktu. Karena itu target regresi dibuat sebagai delta anomali suhu tahunan, lalu direkonstruksi kembali ke level suhu untuk interpretasi.

## Tujuan

- Membangun pipeline data mining end-to-end untuk data climate change, emisi, dan tutupan lahan FAOSTAT.
- Menerapkan lima teknik data mining: clustering dan deteksi anomali, klasifikasi, deep learning, association rule mining, dan time series mining.
- Melakukan hyperparameter tuning ekstensif pada LSTM/GRU karena deep learning menjadi fokus utama.
- Membandingkan deep learning dengan baseline dan model tabular serta menjelaskan alasan hasilnya.
- Menyusun skenario proyeksi 2023-2030 sebagai ilustrasi dampak asumsi emisi dan tutupan lahan.

## Ruang Lingkup

Data berasal dari FAOSTAT: Environment Temperature Change, Environment Land Cover, dan Emissions Totals. Panel akhir berisi 8,128 baris dan 59 kolom untuk 269 negara pada 1992-2022. Training supervised memakai panel global, sedangkan evaluasi utama difokuskan pada ASEAN. Singapura tidak masuk evaluasi supervised karena Temperature\_Change tidak tersedia.

## Manfaat

Pipeline ini menunjukkan bagaimana data mining dapat membaca hubungan antara suhu, emisi, dan tutupan lahan, sekaligus memberi contoh lengkap KDD, validasi temporal, interpretasi model, tuning deep learning, dan pembahasan keterbatasan data.

## TINJAUAN PUSTAKA

Data mining adalah proses menemukan pola bermakna melalui seleksi data, praproses, transformasi, pemodelan, evaluasi, dan interpretasi. Tugas ini mengikuti alur KDD karena data FAOSTAT perlu digabungkan, dibersihkan, ditransformasi, dan dianalisis dengan beberapa teknik yang saling melengkapi.

### Praproses Data

Praproses mencakup missing value, diskretisasi, transformasi, normalisasi, dan seleksi fitur. Transformasi log mengurangi efek outlier pada fitur skewed; delta dan percentage change menangkap laju perubahan; normalisasi penting untuk model berbasis jarak dan neural network.

### Teknik Data Mining

K-Means mengelompokkan negara, DBSCAN mendeteksi country-year anomali, klasifikasi memetakan level suhu ke kategori risiko, Apriori menemukan aturan asosiasi antarfitur terdiskretisasi, dan LSTM/GRU digunakan untuk deret sekuensial. Time series mining memakai ADF, dekomposisi tren/siklus, ACF/PACF, dan split temporal.

## METODE

### Data

Data suhu difilter pada Temperature change dan meteorological year. Data land cover difilter pada Area from CCI\_LC. Data emisi difilter pada Emissions (CO<sub>2</sub>eq) (AR5) dan dideduplicate berdasarkan prioritas sumber. Ketiganya dilebur ke format country-year dan digabung berdasarkan Area dan Year.

| Komponen              | Nilai                                       |
|-----------------------|---------------------------------------------|
| Panel akhir           | 8,128 baris x 59 kolom                      |
| Rentang tahun         | 1992-2022                                   |
| Jumlah negara global  | 269 negara                                  |
| Negara ASEAN target   | 9 negara dengan Temperature_Change tersedia |
| Supervised rows       | 7,859                                       |
| ASEAN supervised rows | 300                                         |

### Tahapan Kegiatan

1. Merge tiga sumber FAOSTAT menjadi panel country-year.
2. EDA: missing value, ADF, korelasi, tren suhu, dan statistik deskriptif.
3. Praproses: drop kolom missing ekstrem, interpolasi per negara, imputasi median, log-transform, delta/pct\_change, diskretisasi, normalisasi, dan seleksi fitur berbasis train split.
4. Pembuatan supervised dataset dengan target delta suhu tahun berikutnya.
5. Implementasi lima teknik data mining dan perbandingan model.
6. Hyperparameter tuning deep learning 288 konfigurasi.
7. Scenario forecasting 2023-2030 dan penyusunan interpretasi hasil.

### Definisi Target dan Validasi Temporal

Target regresi adalah  $\text{target\_next\_year} = \text{Temperature\_Change}(t+1) - \text{Temperature\_Change}(t)$ . Prediksi level direkonstruksi dengan  $\text{predicted\_level} = \text{Temperature\_Change}(t) + \text{predicted\_delta}$ . Split temporal: train sampai 2016, validation 2017-2019, dan test 2020-2022 untuk menghindari leakage.

### Hyperparameter Tuning Deep Learning

Tuning dilakukan pada 288 konfigurasi LSTM/GRU. Model dipilih berdasarkan MAE reconstructed level pada ASEAN validation set; global validation MAE menjadi tie-breaker. Test set tidak digunakan untuk memilih model.

| Parameter        | Nilai diuji   |
|------------------|---------------|
| Model            | GRU, LSTM     |
| Sequence window  | 3, 5, 7 tahun |
| Hidden dimension | 16, 24, 48    |

## Laporan Akhir Data Mining - ASEAN Climate & Land Cover

|                        |                 |
|------------------------|-----------------|
| Learning rate          | 0.001, 0.003    |
| Dropout                | 0.05, 0.15      |
| Jumlah recurrent layer | 1, 2            |
| Weight decay           | 1e-4, 1e-3      |
| Total eksperimen       | 288 konfigurasi |

### Lingkungan Pengembangan

Implementasi dilakukan dengan Python, pandas, numpy, matplotlib, seaborn, scikit-learn, statsmodels, mlxtend, scipy, dan PyTorch. Semua output disimpan pada folder outputs1.

## HASIL DAN PEMBAHASAN

### Analisis Missing Value

Sebanyak 31 dari 59 kolom memiliki missing value. International bunkers memiliki missing 99.62%, sehingga dihapus. Kolom lain yang sparse tetap dipertahankan setelah interpolasi dan imputasi karena dapat menjadi proxy aktivitas ekonomi, agrifood, dan emisi.

| Kolom                     | Jumlah Missing | Persentase |
|---------------------------|----------------|------------|
| International bunkers     | 8097           | 99.62%     |
| Fertilizers Manufacturing | 4701           | 57.84%     |
| Food Processing           | 3789           | 46.62%     |
| Rice Cultivation          | 3407           | 41.92%     |
| Food Packaging            | 3117           | 38.35%     |
| On-farm energy use        | 1919           | 23.61%     |
| Burning - Crop residues   | 1365           | 16.79%     |
| Crop Residues             | 1309           | 16.10%     |


### Uji Stasioneritas dan Tren Suhu

Uji ADF menunjukkan seluruh 9 negara ASEAN yang memiliki data suhu bersifat non-stasioner pada taraf 5%. Rata-rata ASEAN meningkat dengan slope sekitar 0.0309 deg C per tahun dan R<sup>2</sup> 0.5537, sehingga pemodelan delta suhu lebih aman daripada memprediksi level langsung.

| Negara                           | ADF     | p-value | Kesimpulan    |
|----------------------------------|---------|---------|---------------|
| Brunei Darussalam                | -2.4834 | 0.1196  | Non-Stasioner |
| Cambodia                         | -0.5406 | 0.8839  | Non-Stasioner |
| Indonesia                        | -2.6559 | 0.0820  | Non-Stasioner |
| Lao People's Democratic Republic | -0.2804 | 0.9282  | Non-Stasioner |

## Laporan Akhir Data Mining - ASEAN Climate & Land Cover

|             |         |        |               |
|-------------|---------|--------|---------------|
| Malaysia    | -1.3622 | 0.6002 | Non-Stasioner |
| Myanmar     | 0.3096  | 0.9778 | Non-Stasioner |
| Philippines | -0.9345 | 0.7764 | Non-Stasioner |
| Thailand    | -1.2877 | 0.6348 | Non-Stasioner |
| Viet Nam    | -0.6043 | 0.8700 | Non-Stasioner |




*Gambar 1. Tren rata-rata anomali suhu ASEAN 1992-2022.*

### Korelasi Fitur

Heatmap menunjukkan beberapa fitur sangat berkorelasi, misalnya AFOLU dengan LULUCF dan Agrifood systems. Ini wajar karena beberapa indikator merupakan agregat atau subkomponen aktivitas yang sama. Seleksi korelasi tinggi diterapkan dari train split saja untuk mengurangi leakage.

| Fitur A                                                    | Fitur B                                                    | r     |
|------------------------------------------------------------|------------------------------------------------------------|-------|
| Tree-covered areas                                         | Artificial surfaces (including urban and associated areas) | 0.928 |
| Tree-covered areas                                         | Agrifood systems                                           | 0.879 |
| Artificial surfaces (including urban and associated areas) | Energy                                                     | 0.934 |
| AFOLU                                                      | LULUCF                                                     | 0.992 |
| AFOLU                                                      | Net Forest conversion                                      | 0.887 |
| AFOLU                                                      | Agrifood systems                                           | 0.972 |
| LULUCF                                                     | Net Forest conversion                                      | 0.906 |
| LULUCF                                                     | Agrifood systems                                           | 0.944 |




Gambar 2. Korelasi fitur utama pada subset ASEAN.

## Praproses Data


Praproses dilakukan berlapis: kolom missing ekstrem dihapus, interpolasi per negara menjaga kontinuitas panel, NaN tersisa diisi median global, fitur skewed ditransformasi log, delta/pct\_change ditambahkan, suhu dan perubahan fitur didiskretisasi, dan normalisasi dilakukan di pipeline model.

## Clustering dan Deteksi Anomali

K-Means memperoleh silhouette tertinggi pada  $k=2$  dengan skor 0.934. Semua negara ASEAN masuk kluster yang sama. Ini menunjukkan bahwa skala negara sangat besar di luar ASEAN mendominasi pemisahan kluster global. DBSCAN mendeteksi 29 country-year anomali, banyak berasal dari Indonesia, yang sesuai dengan dinamika hutan, kebakaran, dan perubahan lahan yang besar.



*Gambar 3. Analisis silhouette untuk pemilihan jumlah kluster.*




*Gambar 4. Visualisasi PCA hasil K-Means dan posisi negara ASEAN.*

### Klasifikasi Kategori Suhu

Random Forest Classifier memperoleh akurasi global test 0.5437 dan akurasi ASEAN test 0.5500.


HistGradientBoosting Classifier memperoleh akurasi global test 0.5703 dan akurasi ASEAN test 0.6500.

Kinerja klasifikasi terbatas karena batas kategori suhu berdekatan dan variasi suhu bersifat kontinu.



*Gambar 5. Confusion matrix Random Forest Classifier.*





*Gambar 6. Confusion matrix HistGradientBoosting Classifier.*

## Deep Learning dan Hyperparameter Tuning


Tuning deep learning diperluas menjadi 288 konfigurasi. Berdasarkan validation ASEAN, konfigurasi terbaik adalah LSTM dengan window 3, hidden 24, learning rate 0.003, dropout 0.05, 2 recurrent layer, dan weight decay 0.001. MAE validasi ASEAN adalah 0.193, sedangkan MAE test ASEAN 0.222. Perbedaan ini menunjukkan bahwa validation set kecil dapat memilih konfigurasi yang tidak selalu paling stabil pada test set.

Best GRU memiliki MAE validasi ASEAN 0.209 dan test 0.192. Best LSTM memiliki MAE validasi ASEAN 0.193 dan test 0.222. Rata-rata parameter menunjukkan window 7, hidden 48, dropout 0.15, dan dua layer cenderung membantu validasi, tetapi konfigurasi individual terbaik tetap bergantung pada kombinasi parameter.

| Model | Win | Hid | LR    | Drop | Layer | WD     | MAE Val | MAE Test |
|-------|-----|-----|-------|------|-------|--------|---------|----------|
| LSTM  | 3   | 24  | 0.003 | 0.05 | 2     | 0.001  | 0.193   | 0.222    |
| LSTM  | 7   | 48  | 0.003 | 0.15 | 1     | 0.0001 | 0.205   | 0.237    |
| LSTM  | 7   | 48  | 0.001 | 0.05 | 2     | 0.001  | 0.208   | 0.172    |
| GRU   | 3   | 16  | 0.001 | 0.15 | 2     | 0.0001 | 0.209   | 0.192    |
| LSTM  | 3   | 24  | 0.001 | 0.15 | 2     | 0.001  | 0.210   | 0.191    |


## Laporan Akhir Data Mining - ASEAN Climate & Land Cover

|      |   |    |       |      |   |        |       |       |
|------|---|----|-------|------|---|--------|-------|-------|
| LSTM | 7 | 16 | 0.001 | 0.15 | 2 | 0.0001 | 0.210 | 0.244 |
| GRU  | 3 | 48 | 0.003 | 0.15 | 2 | 0.001  | 0.211 | 0.189 |
| LSTM | 7 | 16 | 0.003 | 0.15 | 1 | 0.001  | 0.211 | 0.214 |
| LSTM | 7 | 48 | 0.003 | 0.15 | 2 | 0.001  | 0.212 | 0.243 |
| GRU  | 7 | 16 | 0.001 | 0.15 | 2 | 0.001  | 0.213 | 0.213 |




**Gambar 7. Top konfigurasi deep learning berdasarkan MAE validasi ASEAN.**


## Laporan Akhir Data Mining - ASEAN Climate & Land Cover



Gambar 8. Rata-rata MAE validasi ASEAN berdasarkan nilai hyperparameter.



Gambar 9. Kurva loss konfigurasi GRU terbaik.



Gambar 10. Kurva loss konfigurasi LSTM terbaik.

Deep learning telah diuji secara serius, tetapi data tahunan ASEAN menghasilkan deret pendek. RNN membutuhkan banyak sequence agar parameter recurrent stabil. GRU bisa kompetitif karena lebih sederhana; LSTM bisa menang pada validation karena kapasitas lebih besar tetapi lebih rentan pada variasi sampel kecil.

## Association Rule Mining

Apriori menghasilkan banyak aturan karena fitur diskretisasi memiliki kombinasi berulang. Aturan lift tertinggi banyak melibatkan kondisi Stabil pada AFOLU, LULUCF, forest fires, urban, dan hutan yang berasosiasi dengan Suhu Rendah. Ini menunjukkan asosiasi, bukan hubungan kausal.

| Antecedents                                                                    | Consequents                                                          | Support | Conf. | Lift  |
|--------------------------------------------------------------------------------|----------------------------------------------------------------------|---------|-------|-------|
| D_Lahan_Pertanian=Stabil, D_LULUCF=Stabil, D_Forest fires=Stabil, D_Energy=... | D_Hutan=Stabil, D_AFOLU=Stabil, D_Urban=Stabil, Suhu=Rendah, D_De... | 0.161   | 0.242 | 1.321 |
| D_AFOLU=Stabil, D_Lahan_Pertanian=Stabil, D_Forest fires=Stabil, D_Energy=S... | D_Hutan=Stabil, D_Urban=Stabil, Suhu=Rendah, D_Deforestasi=Stabil... | 0.161   | 0.242 | 1.321 |
| D_AFOLU=Stabil, D_Lahan_Pertanian=Stabil, D_Deforestasi=Stabil, D_Energy=St... | D_Forest fires=Stabil, D_Hutan=Stabil, D_Urban=Stabil, Suhu=Renda... | 0.161   | 0.233 | 1.321 |
| D_AFOLU=Stabil, D_Lahan_Pertanian=Stabil, D_Forest fires=Stabil, D_Energy=S... | Suhu=Rendah, D_Urban=Stabil, D_Hutan=Stabil, D_LULUCF=Stabil         | 0.161   | 0.243 | 1.321 |
| D_AFOLU=Stabil, D_Lahan_Pertanian=Stabil, D_Energy=Stabil                      | D_Forest fires=Stabil, D_Hutan=Stabil, D_Urban=Stabil, Suhu=Renda... | 0.161   | 0.233 | 1.321 |

## Laporan Akhir Data Mining - ASEAN Climate & Land Cover




*Gambar 11. Aturan asosiasi teratas berdasarkan lift.*


### Time Series Mining

Dekomposisi time series menunjukkan perubahan tren total sekitar 0.8764 deg C dan residual standard deviation 0.2587 deg C. ACF/PACF digunakan untuk membaca dependensi lag. Karena data tahunan, komponen seasonal tidak dibaca sebagai musim bulanan, melainkan pola siklus multi-tahun eksploratif.

## Laporan Akhir Data Mining - ASEAN Climate & Land Cover



**Gambar 12. Dekomposisi tren/siklus rata-rata anomali suhu ASEAN.**




**Gambar 13. ACF dan PACF rata-rata anomali suhu ASEAN.**

### Perbandingan Model Regresi


Semua model regresi memprediksi delta suhu dan dievaluasi ulang pada reconstructed level. Pada ASEAN test set, HistGradientBoosting memberikan performa terbaik dengan MAE 0.1269 dan RMSE 0.1552. Model ini unggul karena data memiliki banyak fitur tabular cross-sectional dan hubungan nonlinear antarindikator. Tree boosting lebih efisien pada data tabular kecil-menengah dibanding RNN yang membutuhkan sequence panjang.

## Laporan Akhir Data Mining - ASEAN Climate & Land Cover


| Model                | n  | MAE   | RMSE  | R2     |
|----------------------|----|-------|-------|--------|
| HistGradientBoosting | 20 | 0.127 | 0.155 | 0.227  |
| Random Forest        | 20 | 0.166 | 0.203 | -0.327 |
| Ridge                | 20 | 0.178 | 0.205 | -0.349 |
| Naive zero delta     | 20 | 0.179 | 0.244 | -0.907 |
| GRU                  | 20 | 0.192 | 0.208 | -0.392 |
| Mean baseline        | 20 | 0.210 | 0.273 | -1.394 |
| LSTM                 | 20 | 0.222 | 0.250 | -1.001 |



*Gambar 14. Perbandingan MAE reconstructed level pada ASEAN test set.*




*Gambar 15. Actual vs predicted model terbaik.*



*Gambar 16. Distribusi residual model terbaik.*



## Laporan Akhir Data Mining - ASEAN Climate & Land Cover




Gambar 17. Feature importance model terbaik.

Feature importance menunjukkan Temperature\_Change sebagai prediktor terkuat karena suhu tahun berjalan merupakan baseline autoregresif paling informatif. Fitur manure, food packaging, forest fires, dan agrifood muncul sebagai proxy aktivitas ekonomi, emisi, dan gangguan lahan. Namun importance tidak boleh langsung ditafsirkan sebagai kausalitas.

### Proyeksi Skenario 2023-2030

Scenario forecasting dibuat untuk baseline, high conversion high emission, dan mitigation conservation. Proyeksi ini bersifat ilustratif karena menggunakan slope historis dan adjustment skenario, bukan model fisik iklim terkalibrasi.

| Skenario                      | Rata-rata Prediksi 2030 |
|-------------------------------|-------------------------|
| baseline                      | 1.104 deg C             |
| high_conversion_high_emission | 1.405 deg C             |
| mitigation_conservation       | 0.904 deg C             |



Gambar 18. Proyeksi skenario anomali suhu ASEAN hingga 2030.

### Bias, Keterbatasan, dan Temuan Tidak Terduga

- Pelatihan global meningkatkan jumlah data, tetapi dapat membawa bias karena hubungan fitur global belum tentu identik dengan dinamika ASEAN.
- ASEAN test set hanya memiliki 20 sampel untuk ranking utama, sehingga hasil bersifat indikatif.
- Semua negara ASEAN masuk kluster yang sama karena skala global mendominasi pemisahan kluster; ini temuan metodologis penting, bukan kegagalan model.
- Best LSTM berdasarkan validation tidak menjadi model terbaik pada test; ini menunjukkan risiko variance pada data kecil.
- Scenario forecast bukan proyeksi iklim fisik, melainkan stress test berbasis model data mining dan asumsi skenario.
- Data tahunan tidak mendukung klaim seasonality kuat; dekomposisi dipakai sebagai analisis tren/siklus.
- Singapura dikeluarkan dari supervised evaluation karena target Temperature\_Change tidak tersedia.

### KESIMPULAN DAN SARAN

Tugas akhir ini berhasil mengimplementasikan pipeline data mining komprehensif untuk analisis anomali suhu ASEAN berbasis data FAOSTAT. Seluruh teknik yang diminta telah diterapkan: clustering dan deteksi anomali, klasifikasi, deep learning, association rule mining, dan time series mining. Praproses data meliputi missing value handling, diskretisasi, transformasi, normalisasi, dan seleksi fitur.

Hasil utama menunjukkan bahwa seluruh 9 negara ASEAN dengan data suhu tersedia bersifat non-stasioner, sehingga pemodelan delta suhu merupakan keputusan yang tepat. Tuning deep learning sebanyak 288 konfigurasi menunjukkan konfigurasi validasi terbaik adalah LSTM, tetapi model terbaik keseluruhan pada ASEAN test tetap HistGradientBoosting dengan MAE 0.127. Ini menunjukkan bahwa pada data panel tahunan dengan sequence pendek, model tabular boosting lebih stabil dibanding RNN.

Saran pengembangan berikutnya adalah menambahkan data resolusi lebih tinggi seperti bulanan atau spasial grid, melakukan validasi berbasis negara, menambahkan data eksternal seperti ENSO, curah hujan, dan GDP, serta menguji pendekatan hybrid yang menggabungkan model tabular dan temporal. Metadata kelompok dan identitas anggota perlu dilengkapi manual pada bagian awal dokumen.

## DAFTAR PUSTAKA

- FAOSTAT. 2026. Environment Temperature Change, Land Cover, and Emissions Totals datasets [Internet]. Food and Agriculture Organization of the United Nations. Tersedia pada: <https://www.fao.org/faostat/>
- Han J, Kamber M, Pei J. 2012. Data Mining: Concepts and Techniques. 3rd ed. Waltham (US): Morgan Kaufmann.
- Hochreiter S, Schmidhuber J. 1997. Long short-term memory. Neural Computation. 9(8):1735-1780.
- Cho K et al. 2014. Learning phrase representations using RNN encoder-decoder for statistical machine translation. Proceedings of EMNLP.
- Agrawal R, Srikant R. 1994. Fast algorithms for mining association rules. Proceedings of the 20th International Conference on Very Large Data Bases.
- Dickey DA, Fuller WA. 1979. Distribution of the estimators for autoregressive time series with a unit root. Journal of the American Statistical Association. 74(366):427-431.
- Pedregosa F et al. 2011. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research. 12:2825-2830.
- Paszke A et al. 2019. PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems.